


机器学习与量化投资

张叶青

助理教授

中央财经大学 财经研究院

yeqingzhang@cufe.edu.cn




量化投资：理论到实践

- 理论：市场是有效的（Efficient Market Hypothesis），因此不存在套利机会
- 实践：

“Patterns of price movement are not random. However, they're close enough to random so that getting some excess, some edge out of it, is not easy and not so obvious, thank God.”

Jim Simons

- Former mathematician, founder of Renaissance Technologies
- Net worth: \$21.6 billion
- Medallion fund: 39% annual return after fees (1988–2018); 66% before fees



量化投资：理论到实践

Returns Comparison

Investor	Key Fund/Vehicle	Period	Annualized Returns*
Jim Simons	Medallion Fund	1988–2018	39.1%
George Soros	Quantum Fund	1969–2000	32%*
Steven Cohen	SAC	1992–2003	30%
Peter Lynch	Magellan Fund	1977–1990	29%
Warren Buffett	Berkshire Hathaway	1965–2018	20.5%*
Ray Dalio	Pure Alpha	1991–2018	12%


(Source: For Simons, Dalio, Cohen, Soros: reporting; for Buffett: Berkshire Hathaway annual report; for Lynch: Fidelity Investments.)

- 投资收益 \$ 100B+
- 过去30年中仅1个季度亏损
- Renaissance仅有300员工
- Simons如何做出投资决策?
 - 大数据
 - 前沿数学统计算法
 - 先进的计算机设备

主要内容

- 1. 机器学习简介
- 2. 机器学习与量化投资策略
 - SVM原理分析
 - 应用案例：SVM在量化投资
- 3. 机器学习与基本面研究
 - 解释性建模与预测性建模
 - 应用案例：高管个人特征与公司绩效

主要内容



1. 机器学习简介

■ 2. 机器学习与量化投资策略

- SVM原理分析
- 应用案例：SVM在量化投资

■ 3. 机器学习与基本面研究

- 解释性建模与预测性建模
- 应用案例：高管个人特征与公司绩效

机器学习(Machine Learning)

- 定义：使用算法解析数据，从中学习，然后对世界上的某件事情做出决定或预测
- 2016年3月，人工智能围棋软件AlphaGo以4:1战胜了韩国棋手李世乜九段
- 政策方面，2017 年中国发布《新一代人工智能发展规划》
- 学术研究方面，AEA和AFA已经连续四年设置了机器学习和经济金融的专题
- 金融业界的智能量化投资
 - 投资机器人1分钟的工作量相当于一个成熟分析师40小时的工作量；在认知程度上，投资机器人的水平相当于有3~4年投资经验的投资经理的水平
 - 在量化基金分析来自社交媒体的实时数据时，处理庞大的非结构化数据集变得越来越重要 (Jeffery Ryan)
 - 英国资产管理公司Schroders在推出数据洞察部门，30名数据科学家分析另类数据用于投研

机器学习的现实应用

■ 1. 计算机视觉

- 人脸识别、车牌识别、扫描文字识别、图片内容识别、图片搜索等等

■ 2. 自然语言处理

- 搜索引擎智能匹配、文本内容理解、文本情绪判断，语音识别、输入法、机器翻译等等

■ 3. 社会网络分析

- 用户画像、网络关联分析、欺诈作弊发现、热点发现等等

■ 4. 智能推荐


- 音乐软件的“歌曲推荐”，淘宝的“猜你喜欢”等等

■ 5. 智能量化投资

智能量化投资发展趋势

- 机构的核心竞争力转型
 - 平安资产管理公司 → 科技型资产管理公司
- 技能需求结构
 - 金融机构的招聘中，掌握数字化技能的技术人才更受欢迎
- 认知、分析类工作的自动化
 - 花费更多成本用于算法开发和大数据处理，减少雇佣基金经理
 - BlackRock的一半以上的人类选股师被算法取代
 - Sentient Technologies：完全由人工智能、机器学习运营管理的对冲基金
- 边际回报递增
 - 技术类、运算类的基础设施为固定成本
 - 资管行业的市场集中度提高

量化投资策略构建的流程




收益率预测的数据来源

- 市场微观结构 (e.g., order book imbalance)
- 历史价格数据 (e.g., momentum, reversals)
- 横截面的价格数据 (e.g., pair trading)
- 分析师评级、情绪类指标
- 基本面数据 (e.g., earnings, supply chain indicators)
- 新闻舆情
- “另类数据” (e.g., social media, satellite imagery, credit card transactions)
-

当前的趋势：价格类数据→另类数据

数据量的指数级增长



机器学习算法的分类

- 有监督学习

- 无监督学习

有监督学习(Supervised Learning)

- 训练样本中能看到样本的标签
- 目标：从特征变量(x)到结果变量(y)的预测问题

- 1. 分类问题

根据数据样本上抽取出的特征，判定其属于有限个类别中的哪一个。

- 垃圾邮件识别（结果类别：1、垃圾邮件；2、正常邮件）
- 文本情感褒贬分析（结果类别：1、褒；2、贬）
- 图像内容识别（结果类别：1、喵星人；2、汪星人；3、人类；4、都不是）

- 2. 回归问题

根据数据样本上抽取出的特征，预测一个连续值的结果。

- 电影票房预测
- 北京2个月后的房价预测

无监督学习(Unsupervised Learning)

- 训练样本不对应标记信息
- 目标：通过训练总结出多维数据的内在关联，进一步将高维甚至非结构化的变量转化为低维的、可解释性强的变量
- 现实应用：聚类问题
 - 根据数据样本上抽取出的特征，让样本抱团(相近/相关的样本在一团内)
 - 例如，google的新闻分类、用户群体划分
- 投资研究中的应用：从复杂的数据集中归纳、生成本身难以观测的变量, 从而帮助解决研究中常面临的关键变量难以精确度量的问题

机器学习算法



模型vs.数据




“One tool that Renaissance uses is linear regression, which a high school student could understand.”

—Nick Patterson, RenTech

主要内容

■ 1. 机器学习简介



2. 机器学习与量化投资策略

- SVM原理分析
- 应用案例：基于SVM算法的量化投资策略

■ 3. 机器学习与基本面研究

- 解释性建模与预测性建模
- 应用案例：高管个人特征与公司绩效

SVM原理分析


► 支持向量机 (Support Vector Machine)

- Cortes and Vapnik (1995)
- 基本思想：基于训练集在样本空间中找到一个划分超平面，将不同类别的样本分开
- 优势：擅长解决小样本、非线性及高维模式识别

► 参考资料

- Vapnik, V. (1996) The Nature of Statistical Learning Theory
- Cortes, C., Vapnik, V. (1995) “Support Vector Networks”, Machine Learning 20 (3): 273
- Wikibooks (2016) Support Vector Machines ([Link](#))
- Scikit-Learn (2021) Support Vector Machines ([Link](#))

SVM原理分析



- 线性分类器
- 线性可分
- 高维空间的线性函数：超平面 (hyperplane)
 - $g(x) = \mathbf{w}^T \mathbf{x} + b = 0$
- 判别函数： $f(x) = \text{sgn}[g(x)]$
 - $\mathbf{w}^T \mathbf{x} + b \geq 0 \rightarrow \text{类型 } 1$
 - $\mathbf{w}^T \mathbf{x} + b < 0 \rightarrow \text{类型 } 2$

SVM原理分析




Illustration of SVM



- 样本标记: $(x_i, y_i) \in D, y_i \in \{-1, +1\}$
- 超平面: $w^T x + b = 0$
- 支持向量到超平面的间隔(margin)
 - $margin = \frac{|w^T x + b|}{\|w\|} = \frac{1}{\|w\|}$
 - 误分次数 $\leq \left(\frac{2R}{margin} \right)^2$
- 优化的目标: 最大化间隔
- 约束条件: 样本点必须在H1或H2的某一侧
 $|w^T x_i + b| \geq 1$

$$\min_{w, b} \frac{1}{2} \|w\|^2$$

$$s.t. \quad y_i(w^T x_i + b) - 1 \geq 0 \quad (i = 1, 2, \dots, I)$$


SVM原理分析

- 然而，现实中的大部分样本都是线性不可分的
- 如何处理线性不可分问题？
 - 原始低维空间 $\rightarrow$ 高维空间
 - 线性不可分问题 $\rightarrow$ 线性可分问题
- 如何找到从低维空间到高维空间的转换方法？
 - 核函数 Kernel Function: $K(w, x) = \langle w, x \rangle$
 - 输入低维空间里的向量(w 和 x)
 - 输出经过某个变换后在高维空间里的向量内积值
 - 径向基核函数(RBF kernel): $K(x_k, x_i) = \exp(-\frac{\|x_k - x_i\|^2}{2\sigma^2})$



$$g(x) = c_0 + c_1x + c_2x^2 = ay$$

$$y = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix} = \begin{bmatrix} 1 \\ x \\ x^2 \end{bmatrix}, \quad a = \begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix} = \begin{bmatrix} c_0 \\ c_1 \\ c_2 \end{bmatrix}$$




SVM原理分析

- 给定的训练集，先利用一个已知的非线性映射把多维的输入向量投射到高维空间，然后在得到的高维空间内进行线性分类
- 在损失函数约束下,通过引入松弛变量(slack variables, ξ_i)和惩罚参数(penalty parameter, C)来建立二次规划求解模型
- 最值问题可以通过引入Lagrange方程求得


$$(w^*, b^*) = \arg \min_{w, b, \xi_i} \frac{\|w\|^2}{2} + C \sum_{i=1}^m \xi_i$$
$$s. t. \ y_i(w^T x_i + b) \geq 1 - \xi_i \ (\forall i = 1, \dots, m)$$
$$\xi_i \geq 0 \ (\forall i = 1, \dots, m)$$

SVM在量化投资中的应用

- 支持向量机主要用来解决分类问题（如模式识别、判别分析）和回归问题
 - 分类问题：将股价走势看成两种状态（即涨或跌）
 - 回归问题：预测股票收益率



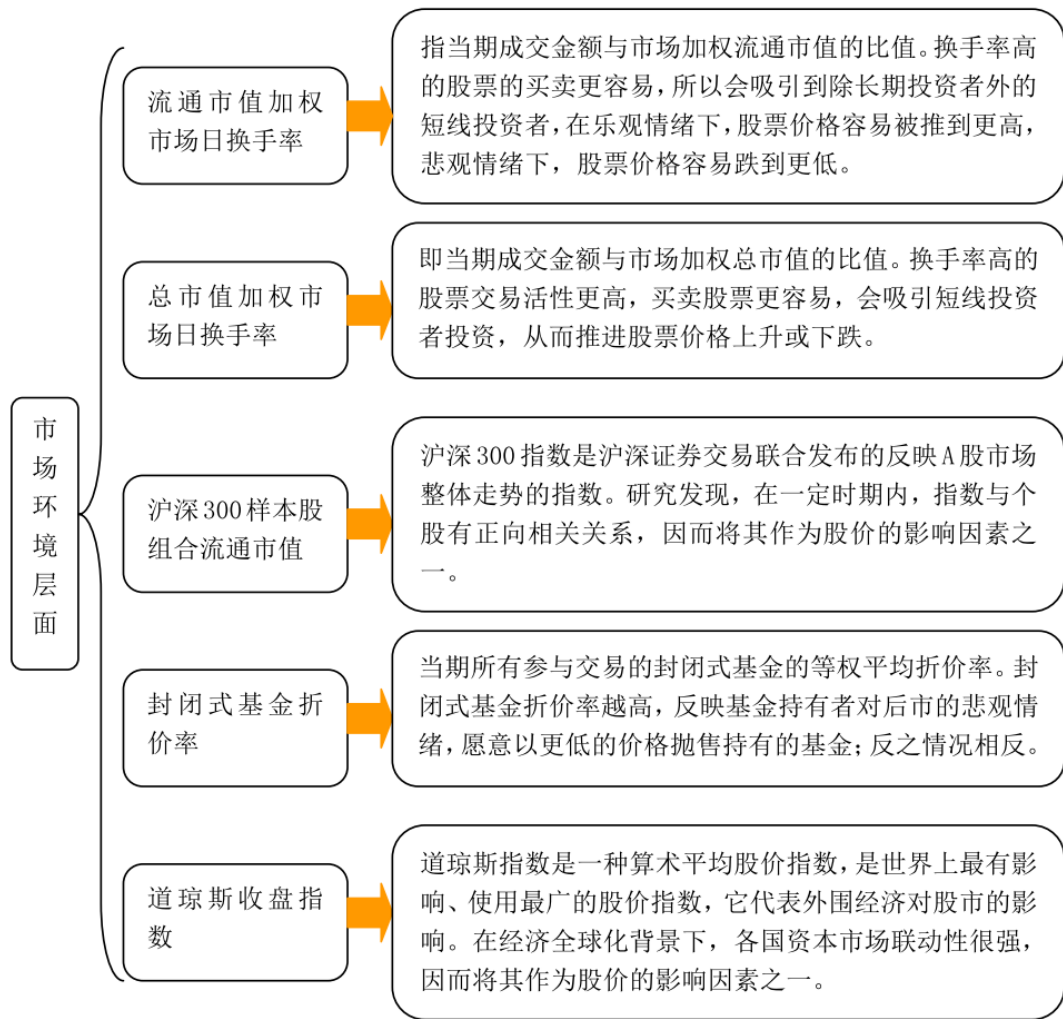
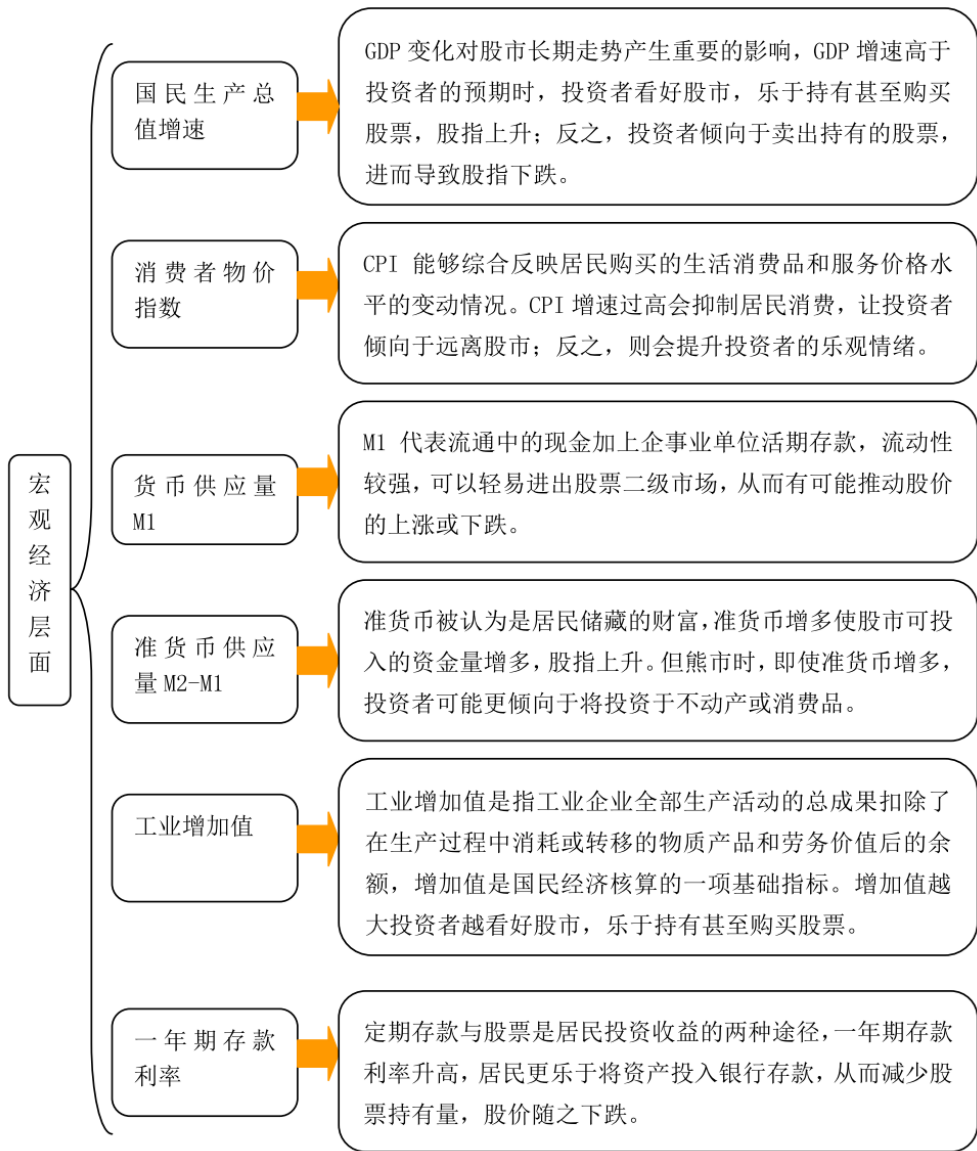
- 举例：道琼斯指数成分股的量化策略构建
- 70%训练样本+30%测试样本
- 输入指标：前一个交易日的价格和交易量信息
- 输出类别
 - 类别1：收益率大于等于零
 - 类别2：收益率小于零
- 策略构建
- 投资策略收益衡量指标：夏普比率



Verizon Communications Inc.

基于SVM和Hurst指数的量化择时策略优化

- 选取**沪深300指数**（2005.4.8—2013.12.31）为测试数据，利用SVM建立回归模型，对沪深300指数每日的收盘价格进行回归拟合
- 将输入数据分成了**市场前期走势**、**市场环境**和**宏观经济**共三个层面
- 考虑到这些指标中可能存在着较大的相关性，使用**主成分分析法**来导出主成分，在尽可能保留原始变量信息的同时减小变量的规模，剔除冗余信息
- 市场前期走势的指标包括上期股指的收盘价、开盘价、最高价、最低价、交易量和交易金额



方向	上涨	下跌
真实	1142	978
预测	1515	605

	上涨		下跌	
真实	1142		978	
预测	Long	Short	Long	Short
	846	296	669	309
占比	74.08%	25.92%	68.40%	31.60%

- SVM在上涨市预测效果更好，在下跌市预测效果较差
- 改进目标：尽可能避开下跌趋势的时间段，争取在上涨趋势的时间段发挥SVM的预测功能以实现更高的收益

Hurst指数

- 分形市场理论：强调市场流动性及投资期限对投资者市场行为的影响
- Hurst指数目前在资本市场中的应用，多数情况下是作为衡量市场记忆性的特征量，它描述市场整体的概念，通过计算局部Hurst指数来预测未来市场大致走势。
- 引入局部Hurst指数对大盘的涨跌进行趋势判断，并以此为基础结合SVM回归预测结果构建策略。
- 基于分形市场理论的Hurst指数对于长期股指的走势具有相对准确的预测能力，因此可以作为使用SVM模型的信号，以实现避开明显下跌趋势的时段，提高判断准确性和收益。

Hurst指数计算

$$\overline{X}_j(n) = \frac{1}{n} \sum_{i=1}^n X_{(j-1)n+i}, j = 1, 2, \dots, k, \quad Y_j(r) = X_{(j-1)n+r} - \overline{X}_j(n), r = 1, 2, \dots, n,$$

$$Z_j(r) = Y_j(1) + Y_j(2) + \dots + Y_j(r), r = 1, 2, \dots, n,$$

$$R_j(n) = \max(Z_j(1), Z_j(2), \dots, Z_j(n)) - \min(Z_j(1), Z_j(2), \dots, Z_j(n))$$

$$\left(\frac{R}{S}\right)_n = \frac{1}{k} \sum_{j=1}^k [R_j(n) / S_j(n)]$$

$$\text{其中定义原始子样本标准差为 } S_j(n) = \sqrt{\frac{1}{n} \sum_{r=1}^n [X_{(j-1)n+r} - \overline{X}_j(n)]^2}, \quad j = 1, 2, \dots, k$$

然后根据等式 $\log \left[\left(\frac{R}{S} \right)_n \right] = \log c + H \log n$



进行OLS线性回归，进一步估计出局部Hurst指数

策略构建

- 为了降低交易次数，抓住长波趋势，过滤掉不足以覆盖交易成本的小的波动，我们进一步构造收益函数，优化策略。
- 假设买入交易成本为交易金额的0.4%；卖出交易成本为交易金额的0.5%。
- 交易成本包括佣金、印花税、过户费等。


策略构建

- 当Hurst指数提示上涨市即将到来时，进一步利用SVM进行短期的涨跌判断，然后发出全仓买入、卖出空仓或者继续持仓的指令。
- 若目前是空仓，运用SVM预测指数涨幅大于0.4%,则全仓买入。若涨幅预测在0到0.4%之间，虽然也是上涨，但我们认为这样的涨幅不足以弥补因买入操作而带来的交易成本，所以选择继续空仓。
- 若目前是持仓，预测跌幅小于0.5%，则继续持有，因为一旦卖出空仓则会带来0.5%的交易成本的支出；若跌幅大于0.5%，则选择卖出空仓。
- 当在一段时间内局部 Hurst 指数发生快速的大幅下跌时，采取空仓操作。



策略收益率对比


- 沪深300指数优化策略的收益率：44.37%
- 被动持有指数的收益率：-21.68%
- 未经优化的策略的收益率：3.17%。




机器学习应用于量化投资的潜在问题

- 缺乏透明度，越艰深的算法越难以解释、验证
- 投资者的接受度
 - 完全由算法管理的基金？
 - 比较优势：金融理论基础
- 数据长度与数据时效性的权衡
 - 数据长度有限，基金表现难以评估
 - 市场规律始终在变化
- 资本市场因交易者结构、制度设计等要素的差异而存在异质性
- 所以，量化投资不能仅仅依赖于数据，而是要结合金融学理论研究；可获得的数据量越大，对理论要求越高

AI funds vs. All funds



主要内容

- 1. 机器学习简介
- 2. 机器学习与量化投资策略
 - SVM原理分析
 - 应用案例：基于SVM算法的量化投资策略
-  3. 机器学习与基本面研究
 - 解释性建模与预测性建模
 - 应用案例：高管个人特征与公司绩效

机器学习与基本面研究

■ 核心：讲好故事

■ 1. 无监督学习

- 从复杂的数据集中归纳、生成本身难以观测的变量, 从而帮助解决公司金融研究中常面临的关键变量难以精确度量的问题
- 例如, Bandiera et al. (2017)采用潜在狄利克雷配置方法来分析CEO日常活动记录的数据, 刻画出了“领导型”和“管理型”两种CEO的行为特征, 并进一步发现“领导型”CEO与好的公司业绩更相关
- Li et al. (2018)采用单词植入模型, 构建了五个公司文化价值的指标, 并研究了其对公司行为决策的影响

■ 2. 有监督学习

- 解决预测问题, 能够更好地应对变量之间更加复杂的非线性和交互关系, 在样本外达到更好的拟合效果
- 例如, Gow等 (2016)基于CEO个性特征来预测公司样本外的特征, 包括融资决策、投资决策以及经营表现

解释性建模 vs. 预测性建模

- 以往的公司基本面研究：解释性建模
 - 变量之间的因果关系
 - 先有理论假设，再利用统计模型加以验证
- 解释性建模的局限性
 - 对因果关系的预先假设（比如线性关系、U型关系、指数关系等）
 - 低维变量之间的关系
- 预测性建模
 - 准确预测未来的观测值

解释性建模 vs. 预测性建模

预测性建模的独特意义

- 1. 提出新理论
 - 没有假设变量之间因果关系和变量之间特定的函数形式。因此, 预测性模型能够发掘出数据中更为复杂的规律, 提出并验证新的理论来解释数据中存在的规律, 从而推动解释性模型和理论的进步
- 2. 评估解释性模型的新角度, 比较不同的解释性模型和理论
- 3. 预测能力的强弱程度能够反映理论解释现象的能力的强弱程度
- 总体而言, 预测性模型和解释性模型分别从“预测”和“理解”的角度出发, 但两者之间并非是完全对立的, 反而相辅相成。

高管个人特征与公司业绩

- 现代公司制度下，高管在公司中的作用
- 高管特征与公司绩效的传统研究：关注单一高管特征的因果推断研究
- 本文采用机器学习算法中的Boosting回归树，全面考察了**多维度**高管特征对公司业绩的**预测性**
 - 公司高管的个人特征能够帮助预测公司业绩吗？
 - 在这些可能预测公司绩效的高管特征中，哪些特征更为关键呢？
 - 它们的预测机制又是怎样的？

为什么要采用机器学习的方法来解答上述问题？

■ 1. 时间和环境的变化

- 经济环境的波动可能导致高管特征与公司绩效之间的关联随经济环境波动而动态变化。以往研究最常使用线性拟合模型, 该模型假定变量之间的相关性是恒定的, 并在此基础上进行模型估计, 因此难以在经济环境波动的情形下得到可靠准确的预测模型
- 我国特有的制度和文化环境使得国内高管研究难以直接套用西方的研究结论

■ 2. 理论中的非线性关系与交互作用

- Adams等(2005)发现管理层的特征与组织变量的相互作用影响公司表现
- Kim and Lu (2011): 高管持股比例与公司的风险偏好之间的非线性

Boosting回归树

- 有监督的机器学习方法的目标：从特征变量 (x) 到结果变量 (y) 的预测问题
- 找到一个回归函数 $\hat{f}(x)$ 来最小化损失函数 $\psi(y, f)$ 的期望值：

$$\hat{f}(x) = \arg \min_{f(x)} E_{y|x} [\psi(y, f(x)) | x]$$

- Boosting回归树的基本思想
 - 渐进梯度回归树：从初始训练集中得到一个基回归树，然后在当前预测误差的基础上训练新的基回归树，每次迭代都向损失函数负梯度的方向移动，从而达到损失函数随着迭代次数增加而逐渐减小的效果，最后加权结合多个基回归树得到回归函数

$$\rho = \arg \min_{\rho} \sum_{i=1}^N \psi(y_i, \hat{f}(x_i) + \rho g(x_i))$$

$$\hat{f}(x) \leftarrow \hat{f}(x) + \rho g(x)$$

为什么选择Boosting回归树?

■ 1. 较强的拟合能力

- 根据Hastie等(2009)的总结, 基于“树”的学习器具有易于构建、可解读、对变量的严格单调变换保持不变、不受极端值影响等优点。回归树本身能够进行变量筛选, 因此即使加入不相关的变量, 也不会对结果造成影响。
- 但是, 回归树是一种弱学习器, 单独使用会得到不精确、波动大的结果。因此, Boosting回归树通过对**集成**许多基回归树, 能在尽量保持其固有优势的情况下, 显著提升其准确性

■ 2. 较好的解释性

- 解释性较强的模型 (<https://christophm.github.io/interpretable-ml-book/>)
- 通过计算变量的**相对重要性**和绘制**部分依赖图**来促进我们对理论的探索

- Hastie T, Tibshirani R, Friedman J. The elements of statistical learning [R]. 2009, Springer New York.

变量设计和模型构建

- 被预测变量：公司绩效
 - 财务绩效 (EBITDA) 和市场绩效 (Tobin's Q)
- 基准模型的预测特征变量
 - 公司规模 (log.Asset)、杠杆率 (Leverage)、国有股份占比 (State.Share)、重资产比例 (PPE) 和公司寿命 (Esty)
- “CEO模型”、“董事长模型”的预测特征变量
 - 理论基础和数据可得性的结合
 - 年龄、性别、话语权、年末持股比例、公司外兼职、职能经验、海外经验、学术经验、金融工作背景和政府工作背景

研究设计框架

■ 模型拟合

- 按照一年滚动窗口期的拟合结构, 用Boosting回归树分别对三个模型进行拟合, 在样本内数据中通过参数调整来优化拟合能力, 并将优化后的拟合模型在样本外数据中测试, 评估拟合效果 ($R_{IS}^2, R_{OOS}^2, MSE_{OOS}$)

■ 结果分析

- 变量的相对重要性和部分依赖图

■ 稳健性检验

- 改变滚动时间窗口、改变公司绩效衡量方式、调整Boosting模型的估计参数、更换机器学习方法和更换高管特征变量

主要拟合结果

		基准模型	CEO 模型	提升效果	董事长模型	提升效果
	模型	(1)	(2)	(2) - (1)	(3)	(3) - (1)
$R^2_{IS}(\%)$	Boosting	19.94	22.69	2.75	21.09	1.15
	OLS	9.43	10.46	1.03	10.33	0.90
$R^2_{OOS}(\%)$	Boosting	12.35	13.43	1.08	13.26	0.91
	OLS	9.17	9.36	0.19	9.54	0.37
MSE_{OOS}	Boosting	0.012 4	0.012 3	-0.000 1	0.012 3	-0.000 1
	OLS	0.012 9	0.012 8	-0.000 1	0.012 8	-0.000 1

1. Boosting回归树的拟合效果相对于OLS模型有大幅提高
2. 中国A股上市公司CEO和董事长的个人特征对于预测公司绩效的作用相对于公司自身的特征指标(包括公司规模、杠杆率、国有股份占比、重资产比例和公司寿命) 比较有限

■ 各变量相对重要性排序

■ 持股比例

■ 年龄

排序	CEO 模型		董事长模型	
	变量	相对重要性 (%)	变量	相对重要性 (%)
1	资产负债率	31.77	资产负债率	32.25
2	公司规模	21.27	公司规模	21.30
3	重资产占比	18.52	重资产占比	18.73
4	年龄*	6.45	年龄*	6.39
5	国有控股比例	5.51	公司寿命	5.66
6	公司寿命	5.50	国有控股比例	5.59
7	持股比例*	4.91	持股比例*	4.92
8	影响力 (兼职) *	1.05	管理职能*	0.81
9	专业职能*	1.00	金融工作背景*	0.77
10	学术经验*	0.83	政府背景*	0.75
11	政府背景*	0.76	专业职能*	0.70
12	金融工作背景*	0.68	CEO 董事长兼任*	0.47
13	性别*	0.49	学术经验*	0.42
14	CEO 董事长兼任*	0.49	性别*	0.35
15	生产职能*	0.41	生产职能*	0.34
16	海外经历*	0.35	影响力 (兼职) *	0.34
17	管理职能*	0.00	海外经历*	0.22
	CEO 特征族相对重要性总计	17.43	董事长特征族相对重要性总计	16.47

CEO持股比例对公司绩效的预测模式

- 文献中的三种主流观点
 - 管理者与股东的利益趋同
 - “壕沟防守效应”
 - 没有明显关系
- 非线性
- 刘鲁彬（2012）发现，当高管持股低于约 23% 或高于约 61% 时，其与扣除了非经常性损益后的净资产回报率呈显著正相关，否则呈显著负相关。








图1 CEO 持股比例与财务绩效

- 模型设计基于合理的经济学理论基础
- 问题为先，数据为辅
- 兼顾模型的预测效率和可解释性

参考资料



- 李航. (2012). 统计学习方法
- James, G., Witten, D., Hastie, T., Tibshiranie, R. (2013) An Introduction to Statistical Learning
- Hastie, T., Tibshiranie, R., Friedman, J. (2009) The Elements of Statistical Learning
- Molnar, C. (2021). Interpretable machine learning (<https://christophm.github.io/interpretable-ml-book/>)
- De Prado, M. L. (2018). Advances in financial machine learning. John Wiley & Sons.
- Mullainathan, S., & Spiess, J. (2017). Machine learning: an applied econometric approach. *Journal of Economic Perspectives*, 31(2), 87-106.
- Gu, S., Kelly, B., & Xiu, D. (2020). Empirical asset pricing via machine learning. *The Review of Financial Studies*, 33(5), 2223-2273.

未来的讨论

- 非结构化数据（文本、声音、图像、视频等）
- 无监督学习：构建难以观测的变量（人的性格、能力等）

Q & A